

PHÂN TÍCH VÀ DỰ ĐOÁN NGUY CƠ MẮC BỆNH ALZHEIMER

Báo cáo cuối kỳ môn Học máy

Nhóm thực hiện: Nhóm 5

Hồ Huyền Trang	23001565
Trần Thị Mai Anh	23001497
Đỗ Thị Như Quỳnh	23001556

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Lớp: K68A5 Khoa học dữ liệu

Hà Nội - 2025

Nội dung trình bày

- 1 Tổng quan
- 2 Bộ dữ liệu
- 3 Tiền xử lý dữ liệu
- 4 Giảm chiều dữ liệu
- 5 Thực nghiệm và So sánh các mô hình
- 6 Phân cụm dữ liệu (Clustering)
- 7 Chuyển bài toán về dạng Hồi quy với Softmax
- 8 Chuyển bài toán về dạng Hồi quy với SVM
- 9 So sánh và đánh giá hai mô hình

Bối cảnh thực tế

- **Thực trạng:** Alzheimer là nguyên nhân hàng đầu gây sa sút trí tuệ, tạo gánh nặng lớn về kinh tế và sức khỏe cộng đồng.
- **Vấn đề:** Việc chẩn đoán sớm mang tính sống còn để can thiệp kịp thời, làm chậm tiến trình bệnh và cải thiện chất lượng sống.

Giải pháp tiếp cận

- Ứng dụng **Học máy (Machine Learning)** để phân tích dữ liệu y tế toàn diện (lâm sàng, lối sống, xét nghiệm).
- Mục tiêu: Phát hiện các mẫu phức tạp và mối quan hệ ẩn giữa các yếu tố nguy cơ mà con người khó nhận ra.
- Kết quả: Xây dựng mô hình dự đoán **không xâm lấn**, hiệu quả và độ chính xác cao.

- **Tổng quan:** Bộ dữ liệu bao gồm **35 trường thông tin** đa dạng:
 - Thông tin cá nhân, yếu tố lối sống, tiền sử y tế.
 - Các chỉ số lâm sàng (Clinical metrics).
 - Đánh giá nhận thức – chức năng.
 - Các triệu chứng liên quan đến Alzheimer.
- **Đặc điểm dữ liệu:** Hầu hết các trường đều là **dữ liệu số** (ngoại trừ trường thông tin định danh DoctorInCharge).
- **Cấu trúc biến số:**
 - **16 biến liên tục:** Các chỉ số đo lường với khoảng giá trị khác nhau.
 - **02 biến phân loại (Categorical):** Ethnicity (Sắc tộc) và EducationLevel (Trình độ học vấn).
 - **15 biến nhị phân (Binary):** Biểu thị sự hiện diện của triệu chứng hoặc tiền sử bệnh (0/1).

Tiền xử lý và Phân tích khám phá (EDA)

1. Xử lý và Chuẩn hóa

- **Làm sạch:** Bộ dữ liệu sạch, không có giá trị thiếu (null) hay ngoại lệ (outlier) đáng kể.
- **Mã hóa:** One-hot encoding cho biến Ethnicity; giữ nguyên các biến nhị phân.
- **Chuẩn hóa:** Áp dụng **StandardScaler** cho 16 biến liên tục để đồng nhất thang đo (mean=0, std=1).

2. Đặc điểm quan trọng từ EDA

- **Mất cân bằng dữ liệu:** Tỷ lệ lớp 0 (Không bệnh) gấp đôi lớp 1 (Có bệnh).
- **Tương quan:** Các chỉ số **MMSE**, **FunctionalAssessment**, và **ADL** có tương quan ngược chiều mạnh nhất với biến mục tiêu (bệnh nhân Alzheimer có điểm thấp hơn rõ rệt).

Phương pháp Tuyến tính: PCA và LDA

- **PCA (Phân tích thành phần chính - Không giám sát):**

- Cần giữ lại **15 thành phần (PCs)** để giải thích **>80%** phương sai thông tin.
- *Hạn chế:* Biểu đồ PC1-PC2 cho thấy sự **chồng lấn lớn** giữa hai lớp → Dữ liệu khó phân tách bằng ranh giới tuyến tính đơn giản.

- **LDA (Phân tích phân biệt tuyến tính - Có giám sát):**

- Tận dụng thông tin nhãn để tối ưu hóa phân tách lớp.
- *Kết quả:* Tốt hơn PCA, các đỉnh mật độ tách biệt hơn nhưng vẫn tồn tại vùng giao thoa đáng kể.

UMAP (Uniform Manifold Approximation and Projection)

- Khi sử dụng UMAP có giám sát (Supervised), hai lớp dữ liệu được **tách biệt hoàn toàn** trong không gian 2 chiều.
- **Ý nghĩa:** Tồn tại cấu trúc **phi tuyến** mạnh mẽ liên kết giữa các đặc trưng và bệnh lý.

⇒ **Chiến lược cho mô hình dự đoán:**

- 1 Sử dụng **PCA** để nén dữ liệu (giảm từ 35 xuống 15 chiều) nhằm loại bỏ nhiễu.
- 2 Lựa chọn các mô hình học máy có khả năng xử lý biên quyết định **phi tuyến** (như KNN, SVM Kernel, Random Forest) để đạt hiệu quả tối ưu thay vì các mô hình tuyến tính thuần túy.

1. Tóm tắt: KNN và Softmax Regression

K-Nearest Neighbors (KNN)

- **Đặc điểm:** Học dựa trên khoảng cách, phi tuyến.
- **Dữ liệu gốc:** Đạt hiệu năng **cao nhất** ($\sim 89\%$). Rất nhạy với đặc trưng gốc.
- **PCA:** Giảm mạnh ($\sim 70\%$) do mất mát thông tin khoảng cách.
- **LDA:** Phục hồi tốt ($\sim 83\%$) nhờ không gian phân lớp tối ưu.

Softmax Regression

- **Đặc điểm:** Mô hình tuyến tính, dựa trên xác suất.
- **Dữ liệu gốc:** Ổn định ($\sim 84\%$). Thấp hơn KNN nhưng cân bằng.
- **PCA:** **Rất ổn định** ($\sim 83\%$), ít bị ảnh hưởng bởi giảm chiều.
- **LDA:** Tương đương gốc ($\sim 84\%$).

Nhận xét sơ bộ: KNN "mạnh nhưng nhạy cảm" (biến động lớn), trong khi Softmax "vừa phải nhưng bền vững" (biến động nhỏ).

2. Tóm tắt: Support Vector Machine (SVM)

Hiệu năng mô hình SVM

- **Trên Dữ liệu gốc (Tốt nhất):**
 - Accuracy: **85.1%**.
 - Kernel tối ưu: **RBF**.
 - Khả năng nắm bắt các biên quyết định phi tuyến phức tạp rất tốt.
- **Trên Dữ liệu giảm chiều:**
 - **PCA:** Giảm còn 81.6%. Mất thông tin lớp thiếu sót (Recall thấp). Thời gian huấn luyện tăng.
 - **LDA:** Đạt 83.0%. Kernel tối ưu chuyển sang **Polynomial**. Tốt hơn PCA nhưng chưa bằng dữ liệu gốc.

Nhận xét: SVM đứng giữa KNN và Softmax về độ nhạy cảm với dữ liệu. Nó cần đầy đủ thông tin (dữ liệu gốc) để phát huy tối đa sức mạnh của Kernel RBF.

3. So sánh định lượng: Bảng tổng hợp

Mô hình	Gốc (Full)	PCA (15 dims)	LDA (1 dim)
KNN	Cao nhất (~89%)	Thấp (~70%)	Tốt (~83%)
Softmax	Ổn định (~84%)	Ổn định (~83%)	Tốt (~84%)
SVM	Tốt (~85.1%)	Trung bình (~81.6%)	Tốt (~83%)

Bảng: So sánh Độ chính xác (Accuracy) trên các tập dữ liệu

Phân tích từ bảng số liệu:

- **Vô địch về độ chính xác:** KNN trên dữ liệu gốc.
- **Vô địch về sự ổn định:** Softmax Regression (biến động < 1% giữa các chiến lược).
- **Ảnh hưởng của PCA:** Gây hại nhiều nhất cho KNN (-19%), trung bình cho SVM (-3.5%), và ít nhất cho Softmax (-1%).

4. So sánh định tính: Đặc điểm vận hành

KNN

Ưu điểm:

- Chính xác cao nhất với dữ liệu đầy đủ.
- Học được biên rất phức tạp.

Nhược điểm:

- Tồn chi phí dự đoán (tính toán chậm).
- Kém hiệu quả nếu giảm chiều sai cách (PCA).

Softmax

Ưu điểm:

- Tốc độ cực nhanh.
- Không bị overfit khi giảm chiều.
- Dễ giải thích.

Nhược điểm:

- Không đạt được "đỉnh" chính xác như KNN do giới hạn tuyến tính.

SVM

Ưu điểm:

- Cân bằng tốt (Accuracy cao thứ 2).
- Hiệu quả với Kernel RBF.

Nhược điểm:

- Nhạy cảm với nhiễu khi giảm chiều.
- Thời gian huấn luyện lâu hơn Softmax.

5. Kết luận và Đề xuất lựa chọn

Dựa trên mục tiêu bài toán chẩn đoán Alzheimer, chúng tôi đưa ra các đề xuất sau:

- ➊ **Lựa chọn tối ưu nhất (Best Performance): KNN trên Dữ liệu gốc.**
 - Lý do: Đạt độ chính xác tiệm cận 89%, vượt trội hơn các mô hình khác trong việc phát hiện các mẫu bệnh phức tạp.
- ➋ **Lựa chọn cân bằng (Balanced Choice): SVM (Kernel RBF) trên Dữ liệu gốc.**
 - Lý do: Độ chính xác 85.1%, độ tin cậy cao, ít rủi ro overfitting cục bộ hơn KNN.
- ➌ **Lựa chọn triển khai nhanh (Deployment): Softmax Regression.**
 - Lý do: Nếu hệ thống yêu cầu phản hồi thời gian thực hoặc tài nguyên thấp, độ chính xác 84

1. Tổng quan phương pháp K-Means

Nguyên lý hoạt động


- Là thuật toán học không giám sát (Unsupervised), chia dữ liệu thành K cụm dựa trên khoảng cách.
- Mục tiêu: Tối thiểu hóa tổng bình phương khoảng cách từ các điểm đến tâm cụm.

Thách thức Giải pháp

- Dữ liệu không có nhãn $\rightarrow$ Không biết trước số cụm K tối ưu.
- **Phương pháp đánh giá:** Sử dụng các chỉ số nội tại:
 - ① **Silhouette Score:** Độ biệt lập của cụm (Cao là tốt).
 - ② **Davies-Bouldin Index (DBI):** Độ phân tách (Thấp là tốt).
 - ③ **Calinski-Harabasz (CH):** Độ kết dính (Cao là tốt).

2. K-Means trên dữ liệu PCA


- **Chọn K tối ưu:** $K = 4$ (Dựa trên Silhouette và DBI).
- **Kết quả định lượng:**
 - Silhouette: **0.3766** (Mức trung bình).
 - DBI: 1.03 (Khá tốt).
- **Nhận xét:**
 - Các cụm có ranh giới mờ nhạt, chồng lấn vùng biên.
 - Cấu trúc cụm bị "trộn lẫn" do PCA làm phẳng các quan hệ phi tuyến.
 - Độ chính xác gán nhãn thực tế chỉ đạt khoảng 64.6% (tương đương tỷ lệ lớp đa số).



Hình: K-Means trên không gian PCA

3. K-Means trên dữ liệu UMAP

- **Chọn K tối ưu:** $K = 4$.
- **Kết quả vượt trội:**
 - Silhouette: **0.6785** (Rất tốt).
 - CH Score: **6786** (Cao gấp 10 lần PCA).
- **Nhận xét:**
 - UMAP bẻ gãy các liên kết phi tuyến, tạo ra các "hòn đảo" dữ liệu riêng biệt.
 - Các cụm có độ đặc rất cao và ranh giới tách bạch rõ ràng.
 - Phát hiện được nhóm rủi ro cao (Cụm 3 có tỷ lệ bệnh 41%).



Hình: K-Means trên không gian UMAP


4. DBSCAN: Phân cụm dựa trên mật độ (với PCA)

Nguyên lý DBSCAN

Không cần chọn K trước. Dựa vào bán kính (ϵ) và mật độ tối thiểu ($minPts$). Có khả năng phát hiện nhiễu (Noise).

Kết quả trên PCA:

- Tham số tối ưu:
 $\epsilon = 1.042$, $minPts = 10$.
- Silhouette: 0.338** (Thấp).
- Đặc điểm:**
 - Tìm ra 4 cụm chính và 122 điểm nhiễu.
 - Cụm bị dính chùm, độ đặc thấp.
 - PCA làm "dẹt" khoảng cách khiến DBSCAN khó tách biên.




Hình: DBSCAN trên PCA (Nhiều thấp nhưng cụm dính)

5. DBSCAN trên dữ liệu UMAP

Kết quả trên UMAP:

- Tham số tối ưu:
 $\epsilon = 0.415$, $minPts = 10$.
- **Silhouette: 0.579** (Tốt).
- **Đặc điểm:**
 - Phát hiện nhiều cụm nhỏ và lượng nhiễu lớn (264 điểm).
 - UMAP co cụm quá mạnh khiến dữ liệu bị đứt gãy thành nhiều mảnh nhỏ.
 - Tuy nhiên, các cụm tìm được rất "sạch" (độ tinh khiết cao).



Hình: DBSCAN trên UMAP (Nhiều cụm nhỏ tách biệt)

6. So sánh tổng hợp các mô hình phân cụm

Mô hình	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-Means + PCA	0.38	1.03	712
K-Means + UMAP	0.68	0.37	6786
DBSCAN + PCA	0.34	-	457
DBSCAN + UMAP	0.58	-	5141

Bảng: Tổng hợp chỉ số đánh giá

Nhận định:

- **K-Means + UMAP** là sự kết hợp **hiệu quả nhất** với chỉ số Silhouette vượt trội, cho thấy cấu trúc cụm rõ ràng nhất.
- PCA (cả với K-Means và DBSCAN) đều cho kết quả thấp hơn do hạn chế trong việc xử lý dữ liệu phi tuyến phức tạp của y sinh.

7. Kết luận và Đề xuất

- 1 **Về phương pháp giảm chiều: UMAP** vượt trội hơn hẳn PCA trong bài toán này. Nó giúp "trải phẳng" các bề mặt cong của dữ liệu y tế, làm bộc lộ các cụm tự nhiên mà PCA không thấy được.
- 2 **Về thuật toán phân cụm:**
 - **K-Means:** Phù hợp nhất khi kết hợp với UMAP để tìm ra các nhóm rủi ro chính (như Cụm 3 có tỷ lệ bệnh cao).
 - **DBSCAN:** Hữu ích để phát hiện các trường hợp ngoại lai (outliers/noise), nhưng có xu hướng xé nhỏ dữ liệu quá mức khi dùng với UMAP.
- 3 **Kiến nghị:** Sử dụng mô hình **K-Means trên không gian UMAP ($K = 4$)** để phân tầng rủi ro bệnh nhân, hỗ trợ các bác sĩ khoanh vùng nhóm đối tượng cần theo dõi đặc biệt.

1. Cơ sở lý thuyết và Ý tưởng

Softmax Regression

- Mở rộng từ Logistic Regression cho bài toán đa lớp.
- Xác suất lớp k :

$$P(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad z_k = w_k^T x + b_k$$

Chuyển đổi sang Hồi quy

- **Mục tiêu:** Sử dụng xác suất đầu ra từ Softmax làm biến mục tiêu cho hồi quy tuyến tính.
- **Mô hình hóa:**

$$\hat{y} = w^T x + b$$

- **Tối ưu hóa:** Giảm thiểu MSE giữa xác suất thực tế và xác suất dự đoán.

2. Các bước triển khai mô hình

Quy trình thực hiện gồm 4 bước chính:

- ➊ **Chuẩn bị dữ liệu:** Sử dụng dữ liệu gốc và dữ liệu giảm chiều PCA, chia train-test với các tỉ lệ 8:2, 7:3, 6:4.
- ➋ **Huấn luyện Softmax Regression:**
 - Sử dụng `LogisticRegression(multi_class='multinomial')` trong `scikit-learn`.
 - Lấy xác suất đầu ra `predict_proba` cho lớp 1.
- ➌ **Huấn luyện Hồi quy:** Dùng `LinearRegression` dự đoán xác suất lớp 1 trên tập train.
- ➍ **Đánh giá hiệu suất:** Tính MAE, MSE, và R^2 trên tập test, tổng hợp kết quả để so sánh.

3. Kết quả thực nghiệm: Dữ liệu gốc

Tỉ lệ	Lớp	MAE	MSE	R^2
8:2	1	0.0746	0.0079	0.9228
7:3	1	0.0952	0.0127	0.8937
6:4	1	0.1024	0.0146	0.8824

Bảng: Hiệu năng hồi quy trên Dữ liệu gốc

Nhận xét:

- Mô hình có hiệu suất ổn định với R^2 từ 0.8824 – 0.9228.
- MSE và MAE ở mức thấp (0.0079 – 0.0146, 0.0746 – 0.1024), mô hình dự đoán tốt.
- Tỉ lệ 8:2 đạt kết quả tốt nhất nhờ tập train lớn hơn.

4. Kết quả thực nghiệm: Dữ liệu PCA

Tỉ lệ	Lớp	MAE	MSE	R^2
8:2	1	0.0025	0.00001	0.9998
7:3	1	0.0034	0.00002	0.9997
6:4	1	0.0024	0.00001	0.9998

Bảng: Hiệu năng hồi quy trên Dữ liệu PCA

Nhận xét:

- R^2 rất cao (0.9997 – 0.9998), MSE và MAE gần 0, dự đoán gần như hoàn hảo.
- Hiệu suất ổn định trên mọi tỉ lệ chia dữ liệu.
- Hiệu suất quá hoàn hảo có thể gợi ý hiện tượng **overfitting** do mô hình học gần như tất cả các đặc trưng.

5. Tổng kết và Đánh giá chung

So sánh hai hướng tiếp cận

- **Dữ liệu gốc (Ưu tiên độ ổn định):**
 - $R^2 \approx 0.92$, MSE và MAE thấp.
 - Dự đoán chính xác, hiệu suất ổn định.
- **Dữ liệu PCA (Ưu tiên tối ưu thông tin và tính toán):**
 - $R^2 \approx 0.9998$, MSE và MAE gần bằng 0.
 - Khả năng dự đoán gần như hoàn hảo, nhưng cần chú ý overfitting.
 - Giúp giảm chiều dữ liệu, tăng tốc tính toán.

Kết luận: Chuyển bài toán về dạng hồi quy với Softmax là khả thi và đạt hiệu suất cao. Dữ liệu gốc mang lại kết quả ổn định, dữ liệu PCA tối ưu hóa độ chính xác tuyệt đối nhưng có nguy cơ bị overfitting.

1. Cơ sở lý thuyết và Ý tưởng

Cấu hình SVM (Support Vector Machine)

- **Kernel:** rbf (Radial Basis Function) để xử lý dữ liệu phi tuyến.
- **Tham số:** $C = 1.0$, $\gamma = \text{'scale'}$, $\text{class_weight} = \text{'balanced'}$.
- **Cơ chế quan trọng:** $\text{probability} = \text{True}$ → Cho phép mô hình ước lượng xác suất của lớp đầu ra thay vì chỉ dự đoán nhãn cứng.

Chuyển đổi sang Hồi quy

- **Mục tiêu:** Sử dụng xác suất dự đoán $P(y = 1|x)$ từ SVM làm biến mục tiêu (target) cho mô hình hồi quy tuyến tính.
- **Mô hình hóa:**

$$\hat{y} = w^T x + b$$

- **Tối ưu hóa:** Giảm thiểu sai số bình phương trung bình (MSE) giữa đầu ra của hồi quy và xác suất của SVM.

2. Các bước triển khai mô hình

Quy trình thực hiện gồm 4 bước chính:

- ➊ **Chuẩn bị dữ liệu:** Sử dụng hai bộ dữ liệu (Gốc và PCA) đã chia tập train-test theo các tỉ lệ 8:2, 7:3, và 6:4.
- ➋ **Huấn luyện SVM (Teacher Model):** Huấn luyện SVC trên tập train để học phân phối dữ liệu và sinh ra xác suất `predict_proba` cho lớp 1.
- ➌ **Huấn luyện Hồi quy (Student Model):** Sử dụng `LinearRegression` để học lại xác suất mà SVM đã sinh ra.
- ➍ **Đánh giá hiệu suất:** Đo lường độ khớp của mô hình hồi quy trên tập test bằng các chỉ số: MAE, MSE và R^2 .

3. Kết quả thực nghiệm: Dữ liệu gốc

Tỉ lệ	Lớp	MAE	MSE	R^2
8:2	1	0.0110	0.0002	0.9661
7:3	1	0.0107	0.0002	0.9719
6:4	1	0.0113	0.0002	0.9633

Bảng: Hiệu năng hồi quy trên Dữ liệu gốc

Nhận xét:

- **Hiệu suất rất cao:** R^2 đạt từ 0.96 – 0.97, nghĩa là mô hình giải thích được tới 97% biến thiên của xác suất dự đoán.
- **Sai số thấp:** MSE và MAE cực nhỏ (≈ 0.01), cho thấy dự đoán gần như khớp hoàn hảo với xác suất mục tiêu.
- **Tỉ lệ tối ưu:** tỉ lệ 7:3 cho kết quả tốt nhất ($R^2 = 0.9719$).

4. Kết quả thực nghiệm: Dữ liệu PCA

Tỉ lệ	Lớp	MAE	MSE	R^2
8:2	1	0.0478	0.0031	0.9465
7:3	1	0.0492	0.0034	0.9435
6:4	1	0.0542	0.0040	0.9305

Bảng: Hiệu năng hồi quy trên Dữ liệu PCA

Nhận xét:

- **Hiệu suất tốt:** R^2 duy trì ở mức cao (0.93 – 0.94), dù thấp hơn dữ liệu gốc.
- **Tác động của giảm chiều:** Việc giảm 1/3 số chiều làm mất một phần thông tin, dẫn đến sai số (MSE/MAE) tăng nhẹ so với dữ liệu gốc.
- **Tỉ lệ tối ưu:** 8:2 cho kết quả tốt nhất ($R^2 = 0.9465$) nhờ tập train lớn hơn bù đắp cho lượng thông tin bị mất.

5. Tổng kết và Đánh giá chung

So sánh hai hướng tiếp cận

- **Dữ liệu gốc (Ưu tiên độ chính xác):**

- $R^2 \approx 0.97$, sai số thấp.
- Phù hợp khi cần độ chính xác tuyệt đối trong việc ước lượng xác suất bệnh.

- **Dữ liệu PCA (Ưu tiên tổng quát hóa):**

- $R^2 \approx 0.94$, sai số thấp nhưng cao hơn so với dữ liệu gốc.
- Giúp giảm độ phức tạp tính toán và tránh hiện tượng overfitting.

Kết luận: Việc chuyển đổi bài toán SVM sang hồi quy là **hoàn toàn khả thi** và đạt độ tin cậy cao trên cả hai tập dữ liệu. Dữ liệu gốc mang lại kết quả tối ưu nhất, trong khi PCA là giải pháp thay thế tốt nếu cần tối ưu tài nguyên tính toán.

So sánh Softmax Regression và SVM (RBF)

Tiêu chí	Softmax – Gốc	SVM – Gốc	Softmax – PCA	SVM – PCA
R^2	0.88–0.92	0.96–0.97	≈ 0.9998	0.93–0.95
MSE	0.008–0.015	≈ 0.0002	≈ 0.00001	0.003–0.004
MAE	0.075–0.10	≈ 0.011	≈ 0.003	0.048–0.049
Tỉ lệ tốt nhất	8:2	7:3	8:2	8:2
Đánh giá	Tốt, ổn định	Rất cao	Gần như hoàn hảo	Tốt

So sánh Softmax Regression và SVM (RBF)

- **So sánh tổng quan:**

- Softmax Regression và SVM thể hiện sự khác biệt khi áp dụng trên dữ liệu gốc và dữ liệu sau giảm chiều PCA.
- Hiệu suất phụ thuộc vào việc có giảm chiều dữ liệu hay không.

- **Trên dữ liệu gốc:**

- SVM (RBF) cho hiệu suất vượt trội: R^2 đạt 0.9633–0.9719, $MSE \approx 0.0002$, $MAE \approx 0.011$ và giải thích được khoảng 96–97% biến thiên dữ liệu
- Softmax Regression đạt hiệu suất tốt ($R^2 = 0.88$ –0.92) nhưng kém hơn SVM

- **Trên dữ liệu sau giảm chiều PCA:**

- Softmax Regression thể hiện ưu thế rõ rệt: Chỉ với khoảng 1/3 số chiều dữ liệu ban đầu, R^2 vẫn đạt ≈ 1 . Sai số gần bằng 0, nhưng tiềm ẩn nguy cơ bị overfitting
- SVM suy giảm hiệu suất ($R^2 = 0.93$ –0.95), nhạy cảm với mất mát thông tin

- **Kết luận:**

- Softmax Regression ổn định, phù hợp khi kết hợp với PCA
- SVM rất mạnh trên dữ liệu gốc nhưng kém thích nghi khi giảm chiều

**Cảm ơn thầy cô và các bạn
đã lắng nghe!**